

The background of the slide is a complex, abstract geometric pattern composed of numerous triangles of various sizes and colors. The colors include shades of yellow, orange, red, pink, purple, blue, and green, creating a vibrant and dynamic visual effect. The triangles are arranged in a way that they seem to flow and overlap, giving the background a sense of movement and depth.

Trafik Kazası Analizi ve Risk Haritalaması



AMAÇ ?

- *Trafik Kazası Analizi ve görselleştirilmesi*
- *Trafik kazası verileri kullanılarak kazaların yoğunlaştığı durumların ve nedenlerin görselleştirilmesi*



VERİ SETİ OLUŞTURMA

```
•[2]: import pandas as pd
```

```
veri = {  
    "hava_durumu": [  
        "güneşli", "yağmurlu", "karlı", "sisli", "bulutlu",  
        "yağmurlu", "karlı", "güneşli", "yağmurlu", "sisli",  
        "güneşli", "yağmurlu", "karlı", "bulutlu", "sisli",  
        "güneşli", "yağmurlu", "karlı", "sisli", "bulutlu",  
        "güneşli", "yağmurlu", "karlı", "sisli", "bulutlu",  
        "yağmurlu", "karlı", "güneşli", "yağmurlu", "sisli"  
    ],  
    "yol_durumu": [  
        "kuru", "ıslak", "kaygan", "kaygan", "kuru",  
        "ıslak", "kaygan", "kuru", "ıslak", "kaygan",  
        "kuru", "ıslak", "kaygan", "kuru", "kaygan",  
        "kuru", "ıslak", "kaygan", "kaygan", "kuru",  
        "kuru", "ıslak", "kaygan", "kaygan", "kuru",  
        "ıslak", "kaygan", "kuru", "ıslak", "kaygan"  
    ],  
    "saat_araligi": [  
        "gündüz", "gece", "gündüz", "gece", "gündüz",  
        "gece", "gündüz", "gündüz", "gece", "gece",  
        "gündüz", "gece", "gündüz", "gece", "gündüz",  
        "gece", "gündüz", "gece", "gündüz", "gece",  
        "gündüz", "gece", "gündüz", "gece", "gündüz",  
        "gece", "gündüz", "gece", "gündüz", "gece"  
    ],  
    "trafik_yogunlugu": [  
        "az", "çok", "orta", "çok", "az",  
        "orta", "çok", "az", "çok", "çok",  
        "az", "çok", "orta", "çok", "orta",  
        "az", "çok", "çok", "az", "çok",  
        "az", "çok", "orta", "çok", "az",  
        "çok", "çok", "az", "çok", "çok"  
    ],  
}
```

```
"kaza": [  
    0,1,1,1,0,  
    0,1,0,1,1,  
    0,1,0,1,0,  
    0,1,1,0,1,  
    0,0,1,0,0,  
    1,1,0,1,1  
],
```

```
"yarali_sayisi": [  
    0, 3, 2, 3, 0,  
    0, 4, 0, 3, 3,  
    0, 3, 0, 2, 1,  
    0, 3, 4, 0, 2,  
    0, 0, 2, 0, 0,  
    3, 4, 0, 3, 3  
]
```

```
}
```

DATAFRAME OLUŞTURULDU VE İLK 10 SATIR GÖRÜNTÜLENDİ.

AYRICA VERİ SETİMİZ HAKKINDA GENEL BİR BAKIŞ GÖRMEK İÇİN ;
-TOPLAM KAYIT SAYISI
-TOPLAM KAZA SAYISI
-TOPLAM YARALI SAYISI
SON OLARAK DA TÜM KAYITLARI YÜZDE KAÇINDA KAZA OLDUĞU GÖSTERİLDİ.

```
df = pd.DataFrame(veri)

print(df.head(10))
print("\nToplam kayıt sayısı:", len(df))
print("Toplam kaza sayısı:", df['kaza'].sum())
print("Toplam yaralı sayısı:", df['yarali_sayisi'].sum())
print("Kaza oranı: %", round(df['kaza'].mean()*100, 2))
```

	hava_durumu	yol_durumu	saat_araligi	trafik_yogunlugu	kaza	yarali_sayisi
0	güneşli	kuru	gündüz	az	0	0
1	yağmurlu	ıslak	gece	çok	1	3
2	karlı	kaygan	gündüz	orta	1	2
3	sisli	kaygan	gece	çok	1	3
4	bulutlu	kuru	gündüz	az	0	0
5	yağmurlu	ıslak	gece	orta	0	0
6	karlı	kaygan	gündüz	çok	1	4
7	güneşli	kuru	gündüz	az	0	0
8	yağmurlu	ıslak	gece	çok	1	3
9	sisli	kaygan	gece	çok	1	3

Toplam kayıt sayısı: 30

Toplam kaza sayısı: 16

Toplam yaralı sayısı: 48

Kaza oranı: % 53.33


```
•[2]: import matplotlib.pyplot as plt
```

```
# Trafik yoğunluğuna göre kazaların toplam içindeki payı (%)
kaza_sayisi = df.groupby("trafik_yogunlugu")["kaza"].sum()
toplam_kaza = df["kaza"].sum()
kaza_yuzdesi = (kaza_sayisi / toplam_kaza) * 100

# Sütun grafiği
plt.bar(kaza_yuzdesi.index, kaza_yuzdesi, color="salmon", edgecolor="black")
plt.title("Trafik Yoğunluğuna Göre Kazaların Payı (%)")
plt.xlabel("Trafik Yoğunluğu")
plt.ylabel("Toplam Kazalara Oranı (%)")

for i in range(len(kaza_yuzdesi)):
    plt.text(i, kaza_yuzdesi.iloc[i] + 1, f"{kaza_yuzdesi.iloc[i]:.1f}%", ha="center")

plt.ylim(0, 100)
plt.show()
```



TRAFİK YOĞUNLUĞU DURUMUNA GÖRE KAZA YÜZDELERİ GRAFİKTEKİ GİBİDİR.

YORUM: Genelde trafik yoğunluğu fazla iken kazalar gerçekleşmiş.
Bu grafikte bize trafik yoğunluğu fazla iken riskin daha fazla olduğunu gösterir.


Bu grafik sayesinde, trafik yoğunluğunun kazalara etkisini hızlıca görebiliyoruz:
Çok yoğun → en çok kaza
Orta → az kaza
Az → hiç kaza yok
Böylece trafik yoğunluğunun kaza riskini görselleştirmiş olduk.

```
•[3]: kaza_hava = df.groupby("hava_durumu")["kaza"].sum()
plt.figure(figsize=(6,4))
plt.bar(kaza_hava.index, kaza_hava, color="skyblue", edgecolor="black")
plt.title("Hava Durumuna Göre Kazalar")
plt.ylabel("Kaza Sayısı")
for i in range(len(kaza_hava)):
    plt.text(i, kaza_hava.iloc[i]+0.2, str(kaza_hava.iloc[i]), ha="center")
plt.show()
```




HAVA DURUMUNA GÖRE KAZA SAYISINI ANALİZLEMİŞ OLDU.

YORUM: Genel olarak kazaların yer zemininin aracın kaymasına müsait olduğu(yağmurlu , karlı gibi) veya görüş açısını kısıtlayan sisli havada olduğu görülmektedir.



```
•[4]: kaza_yol = df.groupby("yol_durumu")["kaza"].sum()
plt.figure(figsize=(6,4))
plt.bar(kaza_yol.index, kaza_yol, color="lightgreen", edgecolor="black")
plt.title("Yol Durumuna Göre Kazalar")
plt.ylabel("Kaza Sayısı")
for i in range(len(kaza_yol)):
    plt.text(i, kaza_yol.iloc[i]+0.2, str(kaza_yol.iloc[i]), ha="center")
plt.show()
```



YOL DURUMUNA GÖRE KAZA SAYISI ANALİZİ YAPILDI

YORUM: Zeminin aracın kaymasına yönelik olma durumlarında kaza sayımızın arttığını görüyoruz.


```
•[6]: import matplotlib.pyplot as plt

kaza_saat = df.groupby("saat_araligi")["kaza"].sum()

plt.figure(figsize=(6,4))
plt.bar(kaza_saat.index, kaza_saat, color="purple", edgecolor="black")
plt.title("Saat Aralığına Göre Kazalar")
plt.ylabel("Kaza Sayısı")

for i in range(len(kaza_saat)):
    plt.text(i, kaza_saat.iloc[i]+0.2, str(kaza_saat.iloc[i]), ha="center")

plt.show()
```



SAAT ARALIĞINA GÖRE VERİ SETİMİZİ ANALİZLEDİK.

YORUM : Gece görüşü gündüze göre daha kısıtlı olduğu için gündüze göre daha fazla kaza meydana gelmiş.



```
[7]: import matplotlib.pyplot as plt

yarali_saat = df.groupby("saat_araligi")["yarali_sayisi"].sum()

plt.figure(figsize=(6,4))
plt.bar(yarali_saat.index, yarali_saat, color="orange", edgecolor="black")
plt.title("Saat Aralığına Göre Yaralı Sayısı")
plt.ylabel("Toplam Yaralı Sayısı")

for i in range(len(yarali_saat)):
    plt.text(i, yarali_saat.iloc[i]+0.2, str(yarali_saat.iloc[i]), ha="center")

plt.show()
```



YARALI SAYISI SAAT ARALIĞI İLİŞKİSİNİ ANALİZLEMİŞ OLDUK.

YORUM: Bu analiz bize gece kaza şiddetinin daha yüksek olduğunu ve daha ciddi kazalar yapıldığını yaralı sayısı artışı ile gösteriyor..


```
•[9]: import matplotlib.pyplot as plt

yarali_trafik = df.groupby("trafik_yogunlugu")["yarali_sayisi"].sum()

plt.figure(figsize=(6,4))
plt.bar(yarali_trafik.index, yarali_trafik, color="orange", edgecolor="black")
plt.title("Trafik Yoğunluğuna Göre Yaralı Sayısı")
plt.xlabel("Trafik Yoğunluğu")
plt.ylabel("Toplam Yaralı Sayısı")

for i in range(len(yarali_trafik)):
    plt.text(i, yarali_trafik.iloc[i]+0.2, str(yarali_trafik.iloc[i]), ha="center")

plt.show()
```



*TRAFİK YOĞUNLUĞUNA GÖRE
TOPLAM YARALI SAYISI ANALİZİ
YAPTIK.*

YORUM: Trafikin yoğunluğunun yoğunlaştığı bölgede araç yoğunluğundan dolayı zincirleme kaza sayısı yüksek olabildiğinden yaralı sayısının yüksek olduğunu düşündüm.

NEDEN LİNEER REGRESYON KULLANILDI?

- ✓ Lineer regresyon sayısal analiz için daha uygundur.
- 📈 Lojistik regresyon kategorik yani oldu/olmadı gibi koşullarda daha net bir sonuç verir.
- ❑ Hedef: **yaralı sayısı** → sayısal değer
- ❑ Lineer regresyon → sayısal tahmin yapar
- ❑ Lojistik regresyon → sadece sınıflandırma (0/1) için
- ❑ Bu yüzden lineer regresyon tercih edildi

```
[14]: from sklearn.linear_model import LinearRegression
import numpy as np
import matplotlib.pyplot as plt

# Kategorik değişkeni sayıya çeviriyoruz (trafik yoğunluğu)
df['trafik_kodu'] = df['trafik_yogunlugu'].map({"az":0, "orta":1, "çok":2})

# Model oluşturma
X = df[['trafik_kodu']]
y = df['yarali_sayisi']

model = LinearRegression()
model.fit(X, y)

# Tahmin
df['tahmin'] = model.predict(X)

# Trafik yoğunluğuna göre gruplayıp toplamaları alıyoruz
gercek_toplam = df.groupby("trafik_yogunlugu")["yarali_sayisi"].sum()
tahmin_toplam = df.groupby("trafik_yogunlugu")["tahmin"].sum()

# Çizgi grafiği
index = np.arange(len(gercek_toplam))

plt.figure(figsize=(7,5))
plt.plot(index, gercek_toplam, marker='o', color='orange', label='Gerçek')
plt.plot(index, tahmin_toplam, marker='s', color='blue', label='Tahmin')

plt.xticks(index, gercek_toplam.index)
plt.title("Trafik Yoğunluğuna Göre Yaralı Sayısı: Gerçek vs Tahmin")
plt.xlabel("Trafik Yoğunluğu")
plt.ylabel("Yaralı Sayısı")
plt.legend()
plt.grid(True)
plt.show()
```

KODUMUZ NEYİ ANLATIYOR? LINEER REGRESYONU NASIL KULLANDIK?

Trafik yoğunluğunu sayısal olarak kodlayıp lineer regresyon ile yaralı sayısını tahmin ettik. Çizgi grafikte gerçek ve tahmin değerleri yan yana gösterilerek model performansını görselleştirmiş olduk.

Kategorik veriyi sayısal hale getirdik:

“az”, “orta”, “çok” gibi trafik yoğunluğu ifadelerini **0, 1, 2** olarak kodladık.

Bunun amacı: Makine öğrenmesi modelleri sayısal veri ister, bu yüzden kategorik veriyi sayıya çevirdik.

Lineer Regresyon Modeli kurduk:

$x \rightarrow$ trafik yoğunluğu (0,1,2)

$y \rightarrow$ yaralı sayısı

Modeli eğittik (**fit**) ve her trafik yoğunluğu için tahmin edilen yaralı sayısını aldık (**predict**).

Veriyi gruplayıp toplamaları aldık:

Her trafik yoğunluğu için gerçek yaralı sayısı ve tahmin edilen yaralı sayısı topladık.

Böylece “az”, “orta”, “çok” için toplam yaralı sayısını karşılaştırabiliriz.

Çizgi grafiği ile görselleştirdik:

Turuncu çizgi $\rightarrow$ Gerçek yaralı sayısı

Mavi çizgi $\rightarrow$ Tahmin edilen yaralı sayısı

Grafik, modelin ne kadar doğru tahmin yaptığını ve trafik yoğunluğu arttıkça yaralı sayısının nasıl değiştiğini gösteriyor.

Grid ve marker'lar grafiği okunabilir kılıyor.



Biz Burada Neyi Tahmin Ettik?

Tahmin edilen değer: Her trafik yoğunluğu seviyesinde yaralı sayısı.

Baz aldığımız veri:

Gözlem verisi → Elimizdeki **df** veri setinde bulununan kazalar ve yaralı sayıları.

Bağımsız değişken (X) → **trafik_yogunlugu** (az, orta, çok → 0,1,2 olarak kodlandı).

Bağımlı değişken (y) → **yarali_sayisi** (her kaza için kaydedilmiş yaralı sayısı).

ÇIKARIM:

Trafik yoğunluğu arttıkça genellikle yaralı sayısı da artıyor.


Lineer regresyon modeli, bu ilişkiyi en uygun doğruyla tahmin etmeye çalışıyor.

Grafik, modelin tahminlerinin gerçek veriye ne kadar yakın olduğunu gösteriyor.

Yani özetle:

"Trafik yoğunluğu seviyesini baz alarak, o seviyedeki toplam yaralı sayısını tahmin ettik."

Trafik Yoğunluğuna Göre Yaralı Sayısı: Gerçek vs Tahmin



YAPILAN LİNEER REGRESYONUN HATA PAYININ BULUNMASI

```
[4]: from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_absolute_error
import numpy as np
import matplotlib.pyplot as plt

# Ortalama Mutlak Hata hesapla
mae = mean_absolute_error(gercek_toplam, tahmin_toplam)

fark = gercek_toplam - tahmin_toplam
print(" ♦ Gerçek Yaralı Sayısı:\n", gercek_toplam)
print("\n ♦ Tahmin Edilen Yaralı Sayısı:\n", tahmin_toplam)
print("\n ♦ Gerçek - Tahmin Farkı:\n", fark)
print(f"\n ♦ Ortalama Mutlak Hata (MAE): {mae:.2f}")
```

```
 ♦ Gerçek Yaralı Sayısı:
trafik_yogunlugu
az      0
orta    5
çok     43
Name: yarali_sayisi, dtype: int64
```

```
 ♦ Tahmin Edilen Yaralı Sayısı:
trafik_yogunlugu
az     -0.706134
orta    6.412268
çok    42.293866
Name: tahmin, dtype: float64
```

```
 ♦ Gerçek - Tahmin Farkı:
trafik_yogunlugu
az      0.706134
orta   -1.412268
çok     0.706134
dtype: float64
```

```
 ♦ Ortalama Mutlak Hata (MAE): 0.94
```


- 
- *Gerçek Yaralı Sayısı: Her trafik yoğunluğu kategorisinde kaç yaralı olduğu. Örnek: “çok” yoğunlukta 43 yaralı var.*
 - *Tahmin Edilen Yaralı Sayısı: Lineer regresyon modelimizin tahmini. Örnek: “çok” yoğunlukta 42.29 yaralı tahmin edilmiş.*
 - *Ortalama Mutlak Hata (MAE): Tüm kategorilerde ortalama sapmayı veriyor. Bu sayede modelin doğruluğunu tek bir sayı ile görebiliyoruz.*
 - *Modelimiz lineer regresyon kullanarak trafik yoğunluğuna göre yaralı sayısını tahmin ediyor.*
 - *Gerçek Yaralı Sayısı → Her trafik yoğunluğu kategorisinde gerçekten kaç kişi yaralandı.*
 - *Az: 0*
 - *Orta: 5*
 - *Çok: 43*
 - *Tahmin Edilen Yaralı Sayısı → Modelin tahmini:*
 - *Az: -0.7 (yani model burada hafifçe eksik tahmin etmiş)*
 - *Orta: 6.4 (model biraz fazla tahmin etmiş)*
 - *Çok: 42.3 (model neredeyse doğru tahmin etmiş)*



Fark (Gerçek – Tahmin) → Modelin her trafik yoğunluğu kategorisinde ne kadar sapma yaptığını gösterir:

- *Az yoğunlukta: 0.7 kişi eksik tahmin*
- *Orta yoğunlukta: 1.4 kişi fazla tahmin*
- *Çok yoğunlukta: 0.7 kişi eksik tahmin*

Bu farklar, modelin özellikle yüksek trafik yoğunluğunda gerçeğe oldukça yakın tahminler ürettiğini, küçük sapmaların daha çok “az” ve “orta” yoğunlukta görüldüğünü gösteriyor.

Ortalama Mutlak Hata (MAE) → Modelin tahminlerinin, gerçek yaralı sayısından ortalama 0.94 kişi kadar sapma gösterdiğini ifade eder.

✓ *MAE = Tahminlerin ortalama kaç kişi sapma yaptığını gösterir. Ne kadar küçükse o kadar iyi bir tahmindir.*

Yani lineer regresyon modelim genel olarak gerçek değerlere yakın tahminler yapıyor ve hata miktarı oldukça düşük.

```
[3]: # Hava durumuna göre kaza riski
hava_risk = df.groupby("hava_durumu")["kaza"].mean() * 100

# Yol durumuna göre kaza riski
yol_risk = df.groupby("yol_durumu")["kaza"].mean() * 100

# Saat aralığına göre kaza riski
saat_risk = df.groupby("saat_araligi")["kaza"].mean() * 100

# Trafik yoğunluğuna göre kaza riski
trafik_risk = df.groupby("trafik_yogunlugu")["kaza"].mean() * 100

print(" ♦ Hava durumuna göre kaza riski (%)")
print(hava_risk.round(2))
print("\n ♦ Yol durumuna göre kaza riski (%)")
print(yol_risk.round(2))
print("\n ♦ Saat aralığına göre kaza riski (%)")
print(saat_risk.round(2))
print("\n ♦ Trafik yoğunluğuna göre kaza riski (%)")
print(trafik_risk.round(2))
```

Beraber risk analizimizin sonuçlarına bakalım!

Hava koşullarının elverişsiz olduğu ,görüşün daha kısıtlı olduğu, trafik yoğunluğunun arttığı , zeminin kaymaya müsait olduğu durumlarda kaza riski artıyor.

♦ Hava durumuna göre kaza riski (%)

```
hava_durumu
bulutlu      50.00
güneşli      0.00
karlı        83.33
sisli        50.00
yağmurlu     75.00
Name: kaza, dtype: float64
```

♦ Yol durumuna göre kaza riski (%)

```
yol_durumu
kaygan       66.67
kuru         20.00
ıslak        75.00
Name: kaza, dtype: float64
```

♦ Saat aralığına göre kaza riski (%)

```
saat_araligi
gece         66.67
gündüz       40.00
Name: kaza, dtype: float64
```

♦ Trafik yoğunluğuna göre kaza riski (%)

```
trafik_yogunlugu
az           0.0
orta        40.0
çok         87.5
Name: kaza, dtype: float64
```

KAZA RİSKİ ANALİZİNİN GÖRSELLEŞTİRİLMESİ İÇİN KODLAR

```
[4]: import matplotlib.pyplot as plt
import pandas as pd

# Risk oranlarını hesaplıyoruz (%)
hava_risk = df.groupby("hava_durumu")["kaza"].mean() * 100
yol_risk = df.groupby("yol_durumu")["kaza"].mean() * 100
saat_risk = df.groupby("saat_araligi")["kaza"].mean() * 100
trafik_risk = df.groupby("trafik_yogunlugu")["kaza"].mean() * 100

# Hepsini tek tabloya alıyoruz
risk_df = pd.DataFrame({
    "Hava Durumu": hava_risk,
    "Yol Durumu": yol_risk,
    "Saat Aralığı": saat_risk,
    "Trafik Yoğunluğu": trafik_risk
})


# Boş hücreler varsa 0 yapalım (bazı kategoriler birbirinden farklı uzunlukta olabilir)
risk_df = risk_df.fillna(0)

# Grafiği çizelim
risk_df.plot(kind="bar", figsize=(10,6), edgecolor="black")

plt.title("Faktörlere Göre Kaza Riski (%)", fontsize=13, fontweight='bold')
plt.ylabel("Kaza Yapma Olasılığı (%)")
plt.xlabel("Durum / Kategori")
plt.legend(title="Faktör Türü")
plt.grid(True, linestyle="--", alpha=0.5)
plt.show()
```

KAZA RİSK ANALİZİNİN GÖRSELLEŞTİRİLMESİ

Faktörlere Göre Kaza Riski (%)



• Bu Grafik Ne Gösteriyor?

X ekseninde farklı kategoriler (örneğin 'yağmurlu', 'kaygan', 'gece') yer alır.

Her renk, farklı bir faktörü temsil eder: hava, yol, saat veya trafik.

Sütun ne kadar yüksekse, o koşulda kaza riski o kadar fazla.

Örneğin:

"Kaygan" çubuğu yüksek → yol koşulu en riskli etken.

"Gece" çubuğu yüksek → karanlıkta kaza olasılığı fazla.

"Çok yoğun" çubuğu yüksek → trafik artışıyla risk artıyor.

Tüm faktörlerin birlikte değerlendirildiği bu grafikte; kaygan yol, yağmurlu hava, yoğun trafik ve gece saatleri koşullarında kaza riski belirgin şekilde artmaktadır.

Bu durum, riskin bu dört faktör etrafında yoğunlaştığını göstermektedir.

VAKİT AYIRDIĞINIZ İÇİN TEŞEKKÜR EDERİM :)

"Her fren sesi, bir hikaye durdurur;
Her dikkatli adım, bir hayatın nefesini
korur.

Trafik sadece yollar değil,
Sevgiyle, sabırla örölmüş
hayatlarımızdır."

Hem kendimiz hem de diğer canlılar için
önleme kendimizden başladığımız bilinçli
toplumlara!

